



上海大学  
SHANGHAI UNIVERSITY

# 本科毕业论文（设计）

UNDERGRADUATE THESIS (PROJECT)

题    目：基于轻量化神经网络的表情识别系统

学    院：计算机工程与科学学院

专    业：计算机科学与技术

学    号：22122742

学生姓名：朱子凡

指导教师：费子翔

起讫日期：2026 年 2 月 31 日起 5 月 32 日止



姓 名：朱子凡

学 号：22122742

论文题目：基于轻量化神经网络的表情识别系统

## 原创性声明

本人声明：所呈交的论文是本人在指导教师指导下进行的研究工作。除了文中特别加以标注和致谢的地方外，论文中不包含其他人已发表或撰写过的研究成果。参与同一工作的其他同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

签 名： 日 期：2026.05.11

## 本论文使用授权说明

本人完全了解上海大学有关保留、使用学位论文的规定，即：学校有权保留论文及送交论文复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容。

（保密的论文在解密后应遵守此规定）

签 名： 指导教师签名： 日 期：2026.05.11

## 摘 要

随着人工智能与计算机视觉技术的快速发展，人脸表情识别在智能监控、人机交互、在线教育以及医疗辅助等领域具有广泛的应用前景。然而，传统深度卷积神经网络虽然能够取得较高的识别精度，但普遍存在模型参数量大、计算复杂度高、部署成本高等问题，难以满足边缘设备和实时场景下的应用需求。因此，研究一种兼顾识别精度与轻量化特性的表情识别模型具有重要意义。

本文围绕轻量化人脸表情识别任务展开研究，构建了一种基于轻量化神经网络的表情识别系统。首先，选取 FerPlus 与 RAF-DB 两个主流表情识别数据集作为实验基础，并针对原始图像分辨率较低、光照变化明显等问题，设计了一套数据预处理流程。该流程通过超分辨率重建技术将图像由  $48\times 48$  提升至  $224\times 224$ ，同时结合 CLAHE（Contrast Limited Adaptive Histogram Equalization）进行光照增强，并在训练阶段引入随机翻转、随机裁剪等数据增强策略，从而提升模型对复杂环境下表情特征的鲁棒性。

在模型设计方面，本文对 ResNet18、ResNet18+CBAM、ResNet18+ViT、MobileNetV1、MobileNetV2 以及 MobileNetV3Small 等多种主流轻量化网络进行了对比研究。在此基础上，提出了一种 Dynamic-MobileNetV3Small 模型。该模型以 MobileNetV3Small 为主干网络，在深度可分离卷积结构中引入动态感受野模块，通过并行的  $3\times 3$  与  $5\times 5$  Depthwise Convolution 提取不同尺度的表情特征，并利用自适应权重融合机制动态调整不同感受野的重要性，使模型能够针对不同表情自动关注更加有效的局部区域，从而增强多尺度表情特征建模能力。

实验结果表明，本文提出的 Dynamic-MobileNetV3Small 模型在保持较低计算复杂度的同时，实现了较高的识别准确率。在仅约 0.05 GFLOPs 的计算量条件下，模型在测试集上取得了 82.28% 的总体识别准确率，计算量略低于 MobileNetV3Small，而识别精度优于原始模型，验证了所提出方法在轻量化与识别性能之间具有较好的平衡能力。

**关键词：**轻量化神经网络；模型压缩；实时识别；移动计算

## ABSTRACT

With the rapid development of artificial intelligence and computer vision technology, facial expression recognition has shown broad application prospects in intelligent surveillance, human-computer interaction, online education, and medical assistance. However, although traditional deep convolutional neural networks can achieve high recognition accuracy, they generally suffer from large parameter sizes, high computational complexity, and expensive deployment costs, making them difficult to apply in edge devices and real-time scenarios. Therefore, it is of great significance to study a facial expression recognition model that balances both recognition accuracy and lightweight characteristics.

This thesis focuses on lightweight facial expression recognition and constructs an expression recognition system based on lightweight neural networks. First, the FerPlus and RAF-DB datasets are selected as the experimental basis. To address the problems of low image resolution and illumination variations in the original datasets, a data preprocessing pipeline is designed. The preprocessing process employs super-resolution reconstruction to upscale facial images from  $48 \times 48$  to  $224 \times 224$ , while CLAHE (Contrast Limited Adaptive Histogram Equalization) is applied for illumination enhancement. In addition, random data augmentation strategies such as random flipping and random cropping are introduced during training to improve the robustness of the model under complex environments.

In terms of model design, several mainstream lightweight neural networks, including ResNet18, ResNet18+CBAM, ResNet18+ViT, MobileNetV1, MobileNetV2, and MobileNetV3Small, are comparatively studied. Based on these models, a Dynamic-MobileNetV3Small model is proposed. The proposed model adopts MobileNetV3Small as the backbone network and introduces a dynamic receptive field module into the depthwise separable convolution structure. By utilizing parallel  $3 \times 3$  and  $5 \times 5$  depthwise convolutions, the model extracts multi-scale facial expression features, while an adaptive weight fusion mechanism dynamically adjusts the importance of different receptive fields. As a result, the model can automatically focus on more effective local regions for different facial expressions, thereby enhancing multi-scale feature representation capability.

Experimental results demonstrate that the proposed Dynamic-MobileNetV3Small model achieves high recognition accuracy while maintaining low computational complexity. With only about 0.05 GFLOPs computational cost, the proposed model achieves an overall recognition accuracy of 82.28% on the test set. Compared with the original MobileNetV3Small model, the proposed method achieves slightly lower computational

complexity and higher recognition accuracy, verifying its effectiveness in balancing lightweight design and recognition performance.

**Keywords:** lightweight neural network; model compression; real-time recognition; mobile computing

目 录

摘 要 ..... I

ABSTRACT ..... II

**1 绪论 ..... 1**

    1.1 研究背景与意义 ..... 1

    1.2 国内外研究现状 ..... 3

    1.3 本文研究内容 ..... 5

    1.4 论文结构安排 ..... 6

**2 相关理论与关键技术 ..... 8**

    2.1 卷积神经网络基础 ..... 8

    2.2 深度学习表情识别理论 ..... 10

    2.3 轻量化神经网络理论 ..... 12

    2.4 MobileNet 系列网络 ..... 14

    2.5 注意力机制与动态感受野 ..... 16

**3 数据集与数据预处理 ..... 19**

    3.1 实验数据集介绍 ..... 19

    3.2 数据预处理流程 ..... 19

    3.3 数据增强策略 ..... 19

    3.4 数据集划分 ..... 19

**4 轻量化表情识别模型设计 ..... 20**

    4.1 系统总体架构设计 ..... 20

    4.2 基础对比模型设计 ..... 20

    4.3 Dynamic-MobileNetV3Small 模型设计 ..... 20

    4.4 模型复杂度分析 ..... 20

**5 实验设计与结果分析 ..... 21**

    5.1 实验环境配置 ..... 21

|                         |           |
|-------------------------|-----------|
| 5.2 模型训练参数设置 .....      | 21        |
| 5.3 模型对比实验 .....        | 21        |
| 5.4 消融实验 .....          | 21        |
| 5.5 实验结果分析 .....        | 21        |
| <b>6 表情识别系统实现 .....</b> | <b>22</b> |
| 6.1 系统需求分析 .....        | 22        |
| 6.2 系统整体设计 .....        | 22        |
| 6.3 模型部署与推理 .....       | 22        |
| 6.4 系统运行结果展示 .....      | 22        |
| <b>7 总结与展望 .....</b>    | <b>23</b> |
| 7.1 本文工作总结 .....        | 23        |
| 7.2 本文创新点总结 .....       | 23        |
| 7.3 不足与未来展望 .....       | 23        |
| <b>8 参考文献 .....</b>     | <b>24</b> |
| <b>9 附录 .....</b>       | <b>25</b> |
| 9.1 关键代码 .....          | 25        |
| 9.2 实验配置文件 .....        | 25        |
| 9.3 部分实验结果数据 .....      | 25        |
| <b>10 致谢 .....</b>      | <b>26</b> |

# 1 绪论

## 1.1 研究背景与意义

### 1.1.1 人脸表情识别的发展现状

人脸表情是人类情感表达的重要方式之一。心理学研究表明，在人与人的交流过程中，面部表情能够传递大量情绪与行为信息，因此对人脸表情进行自动识别具有重要的理论意义与应用价值。随着人工智能、计算机视觉以及深度学习技术的快速发展，人脸表情识别（Facial Expression Recognition, FER）逐渐成为智能感知领域的重要研究方向，并广泛应用于智能监控、人机交互、在线教育、驾驶行为分析以及医疗辅助等场景。

传统的人脸表情识别方法主要包括人脸检测、特征提取与分类识别三个阶段。早期研究通常采用人工设计特征的方法，例如局部二值模式（LBP）、方向梯度直方图（HOG）、Gabor 小波特征等。这类方法具有实现简单、计算量较小等优点，但由于其特征表达能力有限，容易受到光照变化、遮挡、姿态变化以及个体差异等因素影响，因此在复杂场景中的识别效果较差。

近年来，深度学习技术的兴起极大推动了表情识别领域的发展。卷积神经网络（CNN）能够通过多层卷积结构自动学习图像深层语义特征，相比传统方法具有更强的特征提取能力。以 AlexNet、VGGNet、ResNet 为代表的深度卷积网络在多个公开表情识别数据集上取得了较高准确率。与此同时，Transformer 结构与注意力机制逐渐被引入表情识别任务，通过增强模型对关键区域的关注能力进一步提升识别性能。

然而，随着网络深度不断增加，模型参数量与计算复杂度也迅速提升。高性能模型通常需要大量计算资源支持，难以直接部署于移动端与嵌入式设备中。因此，如何在保证识别精度的同时降低模型复杂度与计算开销，逐渐成为当前表情识别研究中的重点问题。

### 1.1.2 轻量化神经网络的发展趋势

随着移动互联网、物联网以及边缘计算技术的不断发展，深度学习模型逐渐从高性能服务器向移动终端与边缘设备迁移。然而，传统深度卷积神经网络通常存在参数量庞大、计算复杂度高以及推理速度慢等问题，难以满足实时应用需求。因此，轻量化神经网络逐渐成为深度学习领域的重要研究方向。

轻量化网络的核心目标是在减少模型参数量与计算量的同时，尽可能保持较高的识别性能。目前主流的轻量化方法主要包括深度可分离卷积、模型剪枝、参数量化以及知识蒸馏等。其中，以 MobileNet、ShuffleNet 与 EfficientNet 为代表的轻量化卷积神经网络在移动端视觉任务中得到了广泛应用。

MobileNetV1 首次提出深度可分离卷积结构，将标准卷积分解为 Depthwise Convolution 与 Pointwise Convolution，大幅减少了模型计算量。MobileNetV2 在此基础上引入倒残差结构与线性瓶颈结构，进一步提升了特征表达能力。MobileNetV3 结合神经网络架构搜索（NAS）与注意力机制，在准确率与推理效率之间取得了更优平衡。

与此同时，多尺度特征提取与动态感受野机制逐渐受到研究者关注。不同表情在面部区域中的特征分布存在明显差异，例如“高兴”表情主要体现在嘴角区域，而“愤怒”表情则更多依赖眉毛与眼部区域。因此，通过动态调整卷积感受野大小，使模型能够自适应关注不同尺度的特征区域，有助于提升模型对于复杂表情的识别能力。

### 1.1.3 边缘设备与实时识别需求

随着智能终端设备的快速普及，人脸表情识别技术逐渐应用于移动设备、人机交互系统以及实时监控场景中。在这些实际应用环境中，系统不仅需要较高识别准确率，同时还需要满足实时推理、低功耗以及低延迟等要求。

例如，在移动终端设备中，由于硬件资源有限，大型深度学习模型往往难以直接运行；在智能监控与在线交互场景中，系统需要在短时间内完成图像采集、特征提取以及表情分类等任务，因此模型推理速度直接影响用户体验。此外，在边缘计算环境中，本地化推理能够减少数据传输延迟，提高系统实时性，并增强用户隐私保护能力。

因此，仅仅追求模型高准确率已经无法满足实际应用需求。如何设计一种兼顾轻量化、高准确率以及实时性能的人脸表情识别模型，成为当前研究中的关键问题。

### 1.1.4 本课题研究意义

针对当前表情识别模型存在参数量大、计算复杂度高以及难以部署于边缘设备等问题，本文围绕轻量化表情识别模型展开研究，提出了一种基于 Dynamic-MobileNetV3Small 的轻量化表情识别方法。

首先，针对 FerPlus 数据集中存在图像分辨率较低、光照变化明显等问题，本文设计了结合超分辨率重建与 CLAHE 光照增强的数据预处理流程，通过提升图像质量增强模型特征提取能力。

其次，本文以 MobileNetV3Small 为基础网络，引入动态感受野模块，通过并行不同尺度的 Depthwise Convolution 提取多尺度表情特征，并利用自适应权重融合机制动态调整不同尺度特征的重要性，使模型能够根据不同表情自适应关注关键区域，从而提升识别性能。

最后，本文在 FerPlus 与 RAF-DB 数据集上进行了大量实验验证。实验结果表明，所提出的模型在保持较低计算复杂度的同时取得了较好的识别准确率，在轻量化与性能之间实现了较好平衡，为移动端与边缘设备上的表情识别研究提供了一定参考价值。

## 1.2 国内外研究现状

### 1.2.1 传统表情识别方法研究现状

传统人脸表情识别方法主要依赖人工设计特征进行图像表示与分类识别。早期研究通常采用几何特征与纹理特征相结合的方法，通过提取人脸关键点位置变化以及局部纹理信息完成表情分类。

在纹理特征方面，局部二值模式（LBP）由于具有较强的灰度不变性，被广泛应用于表情识别任务。Gabor 小波特征能够有效提取不同方向与尺度的纹理信息，在复杂表情特征建模中具有较好效果。方向梯度直方图（HOG）则通过统计图像局部梯度方向信息实现特征描述。

在分类方法方面，传统研究通常采用支持向量机（SVM）、K 近邻（KNN）以及 Adaboost 等机器学习算法完成表情分类任务。虽然传统方法在小规模数据集上具有一定效果，但由于其依赖人工经验设计特征，因此泛化能力有限，难以适应复杂环境下的人脸表情识别任务。

### 1.2.2 基于深度学习的表情识别研究现状

随着深度学习技术的发展，卷积神经网络逐渐成为表情识别领域的主流方法。CNN 能够自动学习图像深层语义特征，相比传统人工特征具有更强的表达能力。

VGGNet 通过增加网络深度提升特征提取能力，在表情识别任务中取得了较好效果。ResNet 引入残差结构，有效解决了深层网络训练中的梯度消失问题，提高了模型训练稳定性。近年来，注意力机制与 Transformer 结构逐渐应用于表情识别领域，例如 CBAM 能够增强模型对关键通道与空间区域的关注能力，而 Vision Transformer（ViT）则通过全局特征建模提升复杂表情识别能力。

此外，多尺度特征融合逐渐成为研究热点。由于不同表情在面部区域中的特征分布差异明显，研究者开始通过不同尺度卷积核提取局部与全局特征，从而增强模型对复杂表情的识别能力。

### 1.2.3 轻量化神经网络研究现状

随着移动端视觉应用需求不断增加，轻量化神经网络研究逐渐受到广泛关注。MobileNet 系列网络通过深度可分离卷积显著降低模型计算量，在移动设备中具有较高应用价值。ShuffleNet 通过通道重排机制减少计算复杂度，提高网络运行效率。EfficientNet 则采用复合缩放策略，在模型深度、宽度与输入分辨率之间实现平衡优化。

近年来，研究者开始将轻量化网络应用于表情识别任务，通过减少参数量与计算量提升模型实时性能。然而，由于轻量化模型特征提取能力相对有限，在复杂场景下容易出现识别精度下降问题。因此，如何进一步增强轻量化模型的特征表达能力，仍是当前研究的重要方向。

### 1.2.4 注意力机制与动态感受野研究现状

注意力机制能够通过增强模型对关键区域的关注能力，提高特征提取效果。目前常见注意力机制包括 SENet、CBAM 与 ECA 等。其中，CBAM 同时结合通道注意力与空间注意力，能够有效提升模型对关键面部区域的特征感知能力。

与此同时，动态感受野机制逐渐成为研究热点。传统卷积网络通常采用固定大小卷积核进行特征提取，但不同表情所对应的关键区域尺度存在差异，因此固定感受野难以充分适应复杂表情特征。

近年来，研究者开始采用多尺度卷积结构与动态卷积机制增强网络特征表达能力。例如，通过并行不同尺度卷积核提取多尺度特征，并利用注意力机制动态融合不同尺度信息，从而提升模型对复杂目标的感知能力。这类方法为轻量化表情识别模型设计提供了新的研究思路。

### 1.2.5 当前研究存在的问题

虽然当前人脸表情识别技术已经取得较大进展，但仍然存在以下问题：

- (1) 大多数高精度模型参数量较大，计算复杂度较高，难以部署于移动端与边缘设备；
- (2) 轻量化模型虽然能够降低计算量，但容易导致特征表达能力不足，从而影响识别准确率；

(3) 不同表情对应的关键区域存在明显差异，传统固定感受野卷积难以有效适应复杂表情特征；

(4) 数据集普遍存在光照变化、遮挡以及低分辨率等问题，影响模型鲁棒性。

因此，研究一种兼顾轻量化、高准确率以及多尺度特征建模能力的表情识别模型具有重要研究意义。

## 1.3 本文研究内容

### 1.3.1 研究目标

本文旨在设计一种适用于移动端与边缘设备部署的轻量化表情识别模型，在降低模型参数量与计算复杂度的同时，提高模型对复杂表情特征的识别能力。

具体研究目标包括：

(1) 构建适用于表情识别任务的数据预处理流程，提高输入图像质量与模型鲁棒性；

(2) 研究轻量化卷积神经网络结构，降低模型参数量与 FLOPs；

(3) 引入动态感受野机制，增强模型对多尺度表情特征的提取能力；

(4) 在保证模型轻量化的基础上，提高表情识别准确率与实时性能。

### 1.3.2 研究思路与技术路线

本文首先对 FerPlus 与 RAF-DB 数据集进行预处理，通过超分辨率重建提升图像分辨率，并采用 CLAHE 光照增强改善图像质量，同时结合随机翻转、随机裁剪等数据增强策略提升模型泛化能力。

随后，本文以 MobileNetV3Small 为基础网络，对其网络结构进行改进。在深度可分离卷积模块中引入 Dynamic Receptive Field Block，通过并行不同尺度的 Depthwise Convolution 提取多尺度表情特征，并利用自适应权重融合机制动态调整不同尺度特征的重要性。

最后，在 Ubuntu 22.04 与 PyTorch 深度学习框架环境下完成模型训练与实验验证，并与 ResNet18、MobileNetV1、MobileNetV2 等主流模型进行对比分析，验证所提出模型的有效性。

### 1.3.3 本文主要工作

本文主要完成了以下几个方面的工作：

(1) 对 FerPlus 与 RAF-DB 数据集进行了分析与预处理，设计了结合超分辨率重建与 CLAHE 光照增强的数据增强流程；

(2) 对 ResNet18、ResNet18+CBAM、ResNet18+ViT、MobileNetV1、MobileNetV2 以及 MobileNetV3Small 等模型进行了实验对比分析；

(3) 提出了一种 Dynamic-MobileNetV3Small 模型，在 MobileNetV3Small 基础上引入动态感受野模块，实现多尺度特征提取；

(4) 通过大量实验验证了所提出模型在轻量化与识别性能之间具有较好平衡能力。

### 1.3.4 本文创新点

本文的主要创新点如下：

(1) 提出了一种基于 MobileNetV3Small 的动态感受野结构，通过并行  $3\times 3$  与  $5\times 5$  Depthwise Convolution 提取多尺度表情特征；

(2) 引入自适应权重融合机制，使模型能够根据不同表情动态调整不同感受野的重要性；

(3) 结合超分辨率重建与 CLAHE 光照增强，提高低分辨率表情图像的特征质量；

(4) 在较低计算复杂度条件下实现较高识别准确率，在轻量化与性能之间取得较好平衡。

## 1.4 论文结构安排

本文共分为六章，各章节内容安排如下：

第一章为绪论，主要介绍人脸表情识别的研究背景与意义，综述国内外研究现状，并阐述本文的研究内容、技术路线以及创新点。

第二章为相关理论与关键技术，主要介绍卷积神经网络基础理论、轻量化网络结构、MobileNet 系列网络以及注意力机制与动态感受野相关理论。

第三章为数据集与数据预处理，主要介绍 FerPlus 与 RAF-DB 数据集，并详细说明超分辨率重建、CLAHE 光照增强以及数据增强等预处理方法。

第四章为轻量化表情识别模型设计，重点介绍 Dynamic-MobileNetV3Small 模型结构设计、动态感受野模块以及特征融合机制。

第五章为实验设计与结果分析，介绍实验环境、训练参数设置以及模型对比实验与消融实验，并对实验结果进行分析。

第六章为总结与展望，总结本文研究工作与实验成果，并对未来轻量化表情识别研究方向进行展望。

## 2 相关理论与关键技术

### 2.1 卷积神经网络基础

卷积神经网络（Convolutional Neural Network, CNN）是一类广泛应用于计算机视觉领域的深度学习模型，具有较强的图像特征提取能力。相比传统神经网络，CNN能够通过局部连接与参数共享自动学习图像中的边缘、纹理以及高级语义特征，因此在人脸识别、目标检测以及表情识别等任务中得到了广泛应用。

如图 2.1 所示，卷积神经网络通常由卷积层、池化层、全连接层以及输出层组成。网络前部主要负责图像特征提取，后部则完成特征分类任务。




图 2.1 典型卷积神经网络结构示意图

#### 2.1.1 卷积层

卷积层是卷积神经网络中的核心结构，其主要作用是对输入图像进行特征提取。卷积操作通过卷积核在图像上滑动，对局部区域进行加权计算，从而提取图像中的边缘、纹理以及形状等信息。

随着网络层数不断增加，卷积层能够逐渐学习更加抽象的高级语义特征。在人脸表情识别任务中，卷积层能够有效提取眉毛、眼睛、嘴角等关键区域特征，为后续表情分类提供基础。

为了降低模型计算复杂度，本文采用 MobileNetV3Small 中的深度可分离卷积结构，通过将标准卷积分解为逐通道卷积与逐点卷积，在保证特征提取能力的同时减少模型参数量与计算量。

### 2.1.2 池化层

池化层（Pooling Layer）主要用于对特征图进行下采样，从而减少特征图尺寸与模型计算量，同时提高模型对局部平移变化的鲁棒性。

常见池化方式包括最大池化（Max Pooling）与平均池化（Average Pooling）。其中，最大池化能够保留更加显著的局部特征，因此在卷积神经网络中应用更加广泛。

在轻量化网络中，通常使用全局平均池化（Global Average Pooling）替代传统全连接层，从而进一步减少模型参数量并降低过拟合风险。

### 2.1.3 激活函数

激活函数用于为神经网络引入非线性表达能力，使模型能够学习复杂特征之间的映射关系。常见激活函数包括 Sigmoid、Tanh 与 ReLU 等。

ReLU（Rectified Linear Unit）由于计算简单、训练速度快以及能够缓解梯度消失问题，被广泛应用于深度卷积神经网络中。

MobileNetV3Small 中采用了 h-swish 激活函数。相比传统 ReLU 与 Swish 函数，h-swish 在保持较好性能的同时具有更低计算开销，更适用于移动端与轻量化网络。

### 2.1.4 Batch Normalization

Batch Normalization（BN）是一种常用的特征归一化方法，其主要作用是在网络训练过程中对输入特征进行标准化处理，从而缓解内部协变量偏移问题。

BN 能够加快模型收敛速度，提高训练稳定性，并在一定程度上减轻过拟合现象。因此，在现代卷积神经网络中通常会在卷积层后加入 Batch Normalization 层。

### 2.1.5 损失函数与优化器

损失函数用于衡量模型预测结果与真实标签之间的差异，是模型训练的重要组成部分。在表情识别任务中，通常采用交叉熵损失函数（Cross Entropy Loss）完成多分类训练。

优化器用于根据损失函数更新网络参数。常见优化器包括 SGD、Momentum 与 Adam 等。其中，Adam 优化器结合了动量优化与自适应学习率机制，具有收敛速度快、训练稳定等优点，因此在深度学习任务中应用广泛。

本文实验采用交叉熵损失函数作为分类损失，并使用 Adam 优化器完成模型训练，以提高模型训练效率与表情识别性能。

## 2.2 深度学习表情识别理论

人脸表情识别（Facial Expression Recognition, FER）是计算机视觉与模式识别领域的重要研究方向，其目标是通过分析人脸图像中的表情特征，自动识别人物情绪状态。随着深度学习技术的发展，基于卷积神经网络的人脸表情识别方法逐渐成为主流方案，相比传统人工特征方法具有更强的特征学习能力与更高的识别准确率。

深度学习表情识别通常包括人脸检测、图像预处理、特征提取以及表情分类等步骤。通过多层神经网络结构，模型能够自动学习不同表情对应的深层语义特征，从而实现复杂场景下的人脸表情识别任务。

### 2.2.1 人脸表情识别流程

典型的人脸表情识别系统主要包括图像采集、人脸检测、图像预处理、特征提取以及表情分类五个阶段。

首先，系统通过摄像头或公开数据集获取人脸图像。随后，通过人脸检测算法定位人脸区域，并对图像进行裁剪与对齐，以减少背景干扰对模型识别结果的影响。

在图像预处理阶段，通常需要对输入图像进行尺寸统一、归一化以及光照增强等操作，以提升模型鲁棒性。本文采用超分辨率重建与 CLAHE 光照增强方法，提高低分辨率表情图像质量。

随后，深度卷积神经网络对输入图像进行特征提取。网络前层主要提取边缘、纹理等低层特征，而深层网络则能够学习更加抽象的表情语义信息，例如眉毛变化、眼部形态以及嘴角运动等关键区域特征。

最后，通过 Softmax 分类器输出不同表情类别的概率值，并将概率最大的类别作为最终识别结果。常见表情类别包括高兴、愤怒、悲伤、惊讶、中性等。




图 2.2 人脸表情识别基本流程图

### 2.2.2 表情特征提取方法

表情特征提取是人脸表情识别中的关键步骤，其主要目标是从人脸图像中提取能够反映情绪变化的重要特征信息。

传统表情识别方法通常采用人工设计特征，例如局部二值模式（LBP）、方向梯度直方图（HOG）以及 Gabor 特征等。这类方法能够提取局部纹理信息，但由于其特征表达能力有限，在复杂环境中的识别效果较差。

随着深度学习技术的发展，卷积神经网络逐渐成为主流特征提取方法。CNN 能够通过多层卷积结构自动学习图像深层语义特征，相比传统方法具有更强的表达能力。

在表情识别任务中，不同面部区域对表情识别的重要程度不同。例如，“高兴”表情通常主要体现在嘴角区域，而“愤怒”表情则更多依赖眉毛与眼部特征。因此，近年来研究者开始引入注意力机制与多尺度特征提取方法，使模型能够更加关注关键区域信息。

本文基于 MobileNetV3Small 网络，引入动态感受野模块，通过并行不同尺度卷积核提取多尺度表情特征，并利用自适应权重融合机制动态调整不同感受野的重要性，从而提升模型对复杂表情特征的提取能力。

### 2.2.3 分类与识别原理

在人脸表情识别任务中，深度神经网络通过前向传播不断提取图像特征，并最终完成表情分类。

卷积神经网络首先通过卷积层提取局部特征，随后利用池化层降低特征图尺寸，并通过多层网络逐渐学习更加抽象的高级语义特征。在网络最后阶段，通常通过全连接层与 Softmax 分类器输出各类别概率。

Softmax 函数能够将网络输出映射为概率分布，其输出结果表示输入图像属于各个表情类别的概率大小。模型训练过程中，通过交叉熵损失函数计算预测结果与真实标签之间的误差，并利用反向传播算法不断更新网络参数，从而提高模型识别能力。

为了提高模型泛化能力，通常还需要结合数据增强、Batch Normalization 以及 Dropout 等方法减少过拟合现象。此外，在轻量化网络中，需要在模型复杂度与识别准确率之间进行平衡优化，以满足移动端与边缘设备中的实时识别需求。

本文提出的 Dynamic-MobileNetV3Small 模型在保持较低计算复杂度的同时，通过动态感受野机制增强多尺度特征建模能力，从而提高轻量化表情识别模型的整体性能。

## 2.3 轻量化神经网络理论

随着深度学习模型规模不断增加，传统卷积神经网络在获得较高识别精度的同时，也带来了参数量大、计算复杂度高以及推理速度慢等问题。在移动端与边缘设备中，硬件资源通常较为有限，因此需要通过轻量化方法降低模型复杂度，提高模型实时性能。

轻量化神经网络的核心目标是在尽可能减少模型参数量与计算量的同时，保持较高的识别准确率。目前常见轻量化方法包括深度可分离卷积、通道压缩、模型剪枝以及知识蒸馏等。其中，MobileNet 系列网络由于具有较好的轻量化性能，被广泛应用于移动端视觉任务中。

### 2.3.1 深度可分离卷积

深度可分离卷积（Depthwise Separable Convolution）是轻量化网络中的核心结构，其主要思想是将传统标准卷积分解为逐通道卷积（Depthwise Convolution）与逐点卷积（Pointwise Convolution）两个步骤，从而降低模型计算复杂度。

传统卷积在卷积过程中会同时完成空间特征提取与通道特征融合。设输入特征图尺寸为：

$$D_F \times D_F$$

输入和输出通道数分别为：

$$M, N$$

卷积核尺寸为：

$$D_K \times D_K$$

则标准卷积计算量为：

$$D_K^2 \times M \times N \times D_F^2$$


深度可分离卷积首先对每个输入通道分别进行卷积操作，然后利用  $1 \times 1$  卷积完成通道融合，其计算量为：

$$D_K^2 \times M \times D_F^2 + M \times N \times D_F^2$$

因此，深度可分离卷积能够显著减少计算量。当卷积核较大且输出通道数较多时，计算复杂度降低更加明显。

MobileNetV1 首次大规模采用深度可分离卷积结构，在保持较好识别性能的同时显著降低了模型参数量与 FLOPs，因此被广泛应用于轻量化视觉任务中。

#### 1. Depthwise Convolution



#### 2. Pointwise Convolution




图 2.3 深度可分离卷积示意图

### 2.3.2 通道压缩机制

通道压缩机制主要用于减少特征图通道数量，从而降低模型参数量与计算复杂度。在轻量化网络中，通常通过瓶颈结构（Bottleneck）实现通道压缩与特征重建。

MobileNetV2 提出的倒残差结构（Inverted Residual）首先利用  $1 \times 1$  卷积对特征通道进行扩展，随后采用深度可分离卷积进行特征提取，最后再通过  $1 \times 1$  卷积压缩通道数量。

这种结构相比传统残差结构具有更低的参数量，同时能够保留较强特征表达能力。此外，部分轻量化网络还会结合 SE 注意力机制，通过学习不同通道的重要性进一步提升特征利用效率。

在本文提出的 Dynamic-MobileNetV3Small 模型中，同样采用了轻量化通道压缩结构，以减少模型整体计算复杂度并提高推理效率。

### 2.3.3 模型复杂度评价指标

在轻量化神经网络研究中，通常采用参数量（Parameters）、计算量（FLOPs）以及模型大小等指标评价模型复杂度。

参数量用于衡量模型规模大小，参数量越小，模型存储需求越低，更适合移动端部署。

FLOPs（Floating Point Operations）用于衡量模型计算复杂度，其值越低，模型推理速度通常越快。

对于标准卷积，其 FLOPs 计算公式为：

$$2 \times D_K^2 \times M \times N \times D_F^2$$

其中：

- $D_K$  表示卷积核尺寸
- $M$  表示输入通道数
- $N$  表示输出通道数
- $D_F$  表示特征图尺寸

此外，模型推理速度与实时帧率（FPS）也是衡量轻量化模型性能的重要指标。在移动端与边缘设备中，需要综合考虑识别准确率、参数量以及推理效率之间的平衡关系。

本文提出的 Dynamic-MobileNetV3Small 模型在仅约 0.05 GFLOPs 的计算量条件下实现了较高识别准确率，验证了所提出方法在轻量化表情识别任务中的有效性。

## 2.4 MobileNet 系列网络

MobileNet 是 Google 提出的一系列轻量化卷积神经网络，主要面向移动端与嵌入式设备设计。相比传统卷积神经网络，MobileNet 系列在保持较高识别性能的同时，大幅降低了模型参数量与计算复杂度，因此被广泛应用于目标检测、人脸识别以及表情识别等实时视觉任务中。

MobileNet 系列网络主要包括 MobileNetV1、MobileNetV2 与 MobileNetV3 等版本，各版本在网络结构与轻量化方法上不断优化，提高了模型效率与特征表达能力。

#### 2.4.1 MobileNetV1 网络结构

MobileNetV1 是最早提出的轻量化 MobileNet 网络，其核心思想是采用深度可分离卷积（Depthwise Separable Convolution）替代传统标准卷积，从而显著降低模型计算量。

传统卷积会同时完成空间特征提取与通道融合，而 MobileNetV1 将其分解为两个步骤：

##### (1) Depthwise Convolution

对每个输入通道分别进行卷积操作，用于提取空间特征。

##### (2) Pointwise Convolution

采用  $1 \times 1$  卷积完成不同通道之间的信息融合。

相比标准卷积，深度可分离卷积能够大幅减少模型参数量与 FLOPs，因此 MobileNetV1 在移动端设备中具有较高运行效率。

此外，MobileNetV1 还引入宽度缩放因子（Width Multiplier）与分辨率缩放因子（Resolution Multiplier），能够进一步调整模型复杂度，以适应不同硬件平台需求。

#### 2.4.2 MobileNetV2 倒残差结构

虽然 MobileNetV1 显著降低了模型复杂度，但由于过度压缩特征信息，容易导致特征表达能力下降。为解决该问题，MobileNetV2 提出了倒残差结构（Inverted Residual）与线性瓶颈结构（Linear Bottleneck）。

传统残差结构通常先压缩通道后提取特征，而 MobileNetV2 采用相反方式，首先利用  $1 \times 1$  卷积扩展通道数量，然后通过深度可分离卷积提取特征，最后再利用  $1 \times 1$  卷积压缩通道数。

这种结构能够在低计算复杂度条件下保留更多特征信息，提高模型表达能力。同时，MobileNetV2 在输出层采用线性激活函数，避免了 ReLU 在低维空间中的信息损失问题。

倒残差结构不仅提高了模型性能，同时也增强了网络训练稳定性，因此成为后续轻量化网络的重要基础结构。




图 2.4 倒残差结构示意图

### 2.4.3 MobileNetV3Small 网络结构

MobileNetV3 是在 MobileNetV2 基础上进一步优化得到的轻量化网络，其结合了神经网络架构搜索（NAS）与注意力机制，在模型准确率与推理效率之间取得了更优平衡。

MobileNetV3 分为 Large 与 Small 两种结构，其中 MobileNetV3Small 更适用于移动端与边缘设备中的实时任务。

MobileNetV3Small 在网络结构中引入了 SE（Squeeze-and-Excitation）注意力机制，通过学习不同通道的重要性增强关键特征表达能力。同时，网络采用更加高效的 h-swish 激活函数替代传统 ReLU，提高模型非线性表达能力。

相比 MobileNetV2，MobileNetV3Small 在保持较低参数量的同时进一步提高了模型识别性能，因此本文选择其作为基础 Backbone 网络进行改进。




图 2.5 MobileNetV3 Block 示意图

在本文提出的 Dynamic-MobileNetV3Small 模型中，基于 MobileNetV3Small 引入动态感受野模块，通过并行不同尺度卷积核增强模型多尺度特征提取能力，从而提高表情识别性能。

## 2.5 注意力机制与动态感受野

随着深度学习技术的发展，研究者逐渐发现传统卷积神经网络在特征提取过程中对所有区域采用相同处理方式，难以有效突出关键特征区域。因此，注意力机制

（Attention Mechanism）被广泛引入计算机视觉任务中，用于增强模型对重要特征区域的关注能力。

在人脸表情识别任务中，不同表情通常对应不同关键区域。例如，“高兴”表情主要体现在嘴角区域，而“愤怒”表情则更加依赖眉毛与眼部特征。因此，通过注意力机制与动态感受野方法增强模型对关键区域与多尺度特征的提取能力，有助于提高表情识别性能。

### 2.5.1 CBAM 注意力机制

CBAM（Convolutional Block Attention Module）是一种轻量级注意力机制模块，其主要作用是增强模型对重要特征区域的关注能力。CBAM 主要包括通道注意力（Channel Attention）与空间注意力（Spatial Attention）两个部分。

通道注意力主要用于学习不同通道的重要程度。通过对输入特征图进行全局平均池化与最大池化，模型能够获得全局通道信息，并利用共享多层感知机生成通道权重，从而增强重要特征通道。

空间注意力则用于学习图像空间位置的重要程度。该模块通过对特征图进行通道压缩，并利用卷积操作生成空间权重图，使模型更加关注关键区域特征。

CBAM 结构简单、计算开销较低，能够有效提升卷积神经网络特征表达能力，因此被广泛应用于轻量化视觉任务中。本文在对比实验中引入 ResNet18+CBAM 模型，用于分析注意力机制对表情识别性能的影响。

### 2.5.2 Vision Transformer 基础

Transformer 最初应用于自然语言处理领域，随后逐渐被引入计算机视觉任务中。Vision Transformer（ViT）通过自注意力机制实现图像全局特征建模，相比传统卷积神经网络具有更强的全局信息提取能力。

ViT 首先将输入图像划分为多个固定大小的 Patch，并将每个 Patch 映射为特征向量。随后，通过位置编码保留空间位置信息，并利用多头自注意力机制学习不同区域之间的特征关系。

相比传统卷积操作，ViT 能够更有效地捕获远距离特征依赖关系，因此在复杂视觉任务中表现出较强性能。然而，Transformer 通常需要较大数据量与较高计算资源支持，因此在移动端任务中的应用仍受到一定限制。

本文在实验部分对 ResNet18+ViT 模型进行了对比分析，用于研究 Transformer 结构在人脸表情识别任务中的表现。

### 2.5.3 多尺度特征提取

在人脸表情识别任务中，不同表情特征通常具有不同空间尺度。例如，嘴角变化属于局部细粒度特征，而整体面部肌肉变化则属于较大尺度特征。因此，仅使用单一尺度卷积核难以充分提取复杂表情信息。

多尺度特征提取方法通常采用不同大小卷积核并行提取特征。例如：

- 小卷积核更加关注局部纹理与细节信息；
- 大卷积核能够获取更加广泛的上下文信息。

通过融合不同尺度特征，模型能够同时学习局部细节与全局语义信息，从而提高复杂表情识别能力。

近年来，多尺度卷积结构被广泛应用于轻量化网络中。例如 Inception 模块通过并行不同尺度卷积核实现多尺度特征融合，提高模型特征表达能力。

本文提出的 Dynamic-MobileNetV3Small 模型同样采用多尺度特征提取思想，通过并行  $3 \times 3$  与  $5 \times 5$  Depthwise Convolution 提取不同尺度表情特征，从而增强模型对于复杂表情区域的感知能力。

### 2.5.4 动态感受野机制

感受野（Receptive Field）表示卷积神经网络中某一神经元所对应的输入区域大小。传统卷积网络通常采用固定大小卷积核，因此其感受野范围固定，难以适应不同尺度目标特征。

在人脸表情识别任务中，不同表情对应的关键区域大小存在明显差异。例如，“惊讶”表情通常涉及较大范围面部变化，而“轻微悲伤”可能仅表现为局部嘴角变化。因此，固定感受野难以同时兼顾不同尺度特征提取需求。

动态感受野机制通过自适应调整不同卷积尺度的重要性，使模型能够根据输入特征动态选择更加合适的感受范围，从而增强模型特征表达能力。

本文提出的 Dynamic Receptive Field Block 采用并行多尺度 Depthwise Convolution 结构，通过同时提取不同尺度特征，并利用自适应权重融合机制动态调整不同感受野的重要程度，使模型能够更加有效地关注不同表情对应的关键区域。

相比传统固定卷积结构，动态感受野机制能够在保持较低计算复杂度的同时，提高模型对复杂表情特征的建模能力，从而提升整体识别性能。

## 3 数据集与数据预处理

### 3.1 实验数据集介绍

#### 3.1.1 FerPlus 数据集

#### 3.1.2 RAF-DB 数据集

#### 3.1.3 数据集类别分布

### 3.2 数据预处理流程

#### 3.2.1 图像尺寸统一

#### 3.2.2 超分辨率重建

#### 3.2.3 CLAHE 光照增强

#### 3.2.4 数据归一化

### 3.3 数据增强策略

#### 3.3.1 随机翻转

#### 3.3.2 随机裁剪

#### 3.3.3 随机旋转

#### 3.3.4 随机颜色扰动

### 3.4 数据集划分

#### 3.4.1 训练集划分

#### 3.4.2 验证集划分

#### 3.4.3 测试集划分

## 4 轻量化表情识别模型设计

### 4.1 系统总体架构设计

#### 4.1.1 系统功能模块

#### 4.1.2 模型训练流程

#### 4.1.3 表情识别流程

### 4.2 基础对比模型设计

#### 4.2.1 ResNet18 模型

#### 4.2.2 ResNet18 + CBAM 模型

#### 4.2.3 ResNet18 + ViT 模型

#### 4.2.4 MobileNetV1 模型

#### 4.2.5 MobileNetV2 模型

#### 4.2.6 MobileNetV3Small 模型

### 4.3 Dynamic-MobileNetV3Small 模型设计

#### 4.3.1 网络整体结构

#### 4.3.2 Dynamic Receptive Field Block 设计

#### 4.3.3 并行 $3\times 3$ 与 $5\times 5$ Depthwise Conv

#### 4.3.4 自适应权重融合机制

#### 4.3.5 特征融合流程

### 4.4 模型复杂度分析

#### 4.4.1 参数量分析

#### 4.4.2 FLOPs 分析

#### 4.4.3 推理速度分析

#### 4.4.4 模型轻量化优势分析

## 5 实验设计与结果分析

### 5.1 实验环境配置

#### 5.1.1 硬件环境

#### 5.1.2 软件环境

#### 5.1.3 PyTorch 深度学习框架

### 5.2 模型训练参数设置

#### 5.2.1 Batch Size 设置

#### 5.2.2 学习率设置

#### 5.2.3 优化器选择

#### 5.2.4 损失函数设置

### 5.3 模型对比实验

#### 5.3.1 不同模型准确率对比

#### 5.3.2 参数量与 FLOPs 对比

#### 5.3.3 F1-Score 对比

#### 5.3.4 推理效率对比

### 5.4 消融实验

#### 5.4.1 CLAHE 光照增强实验

#### 5.4.2 超分辨率重建实验

#### 5.4.3 Dynamic Receptive Field Block 消融实验

#### 5.4.4 不同卷积核组合实验

### 5.5 实验结果分析

#### 5.5.1 Dynamic-MobileNetV3Small 性能分析

#### 5.5.2 多尺度特征提取效果分析

#### 5.5.3 轻量化与准确率平衡分析

#### 5.5.4 模型优势与不足

## 6 表情识别系统实现

### 6.1 系统需求分析

#### 6.1.1 功能需求

#### 6.1.2 性能需求

### 6.2 系统整体设计

#### 6.2.1 系统架构设计

#### 6.2.2 模块划分

### 6.3 模型部署与推理

#### 6.3.1 模型保存与加载

#### 6.3.2 推理流程设计

#### 6.3.3 实时识别实现

### 6.4 系统运行结果展示

#### 6.4.1 表情识别结果展示

#### 6.4.2 系统界面展示

#### 6.4.3 实际运行效果分析

## 7 总结与展望

### 7.1 本文工作总结

#### 7.1.1 数据预处理工作总结

#### 7.1.2 模型设计工作总结

#### 7.1.3 实验结果总结

### 7.2 本文创新点总结

#### 7.2.1 动态感受野模块创新

#### 7.2.2 轻量化结构优化

#### 7.2.3 多尺度特征融合创新

### 7.3 不足与未来展望

#### 7.3.1 当前模型存在的问题

#### 7.3.2 后续优化方向

#### 7.3.3 表情识别未来研究趋势

## 8 参考文献

## 9 附录

### 9.1 关键代码

### 9.2 实验配置文件

### 9.3 部分实验结果数据

## 10 致谢